

Õpetajate keelemudelite kasutamise analüüs

Mattias Väli, Karl Gustav Loog, Laura Lall,
Sten Marcus Nelson, Kaarel Kütt

4 March 2025

Abstrakt

Käesolev uurimus keskendub Eesti üldhariduskoolide õpetajate vabas vormis vastuste kategoriseerimisele, et selgitada välja tekstirobotite kasutamise seotud peamised teemad ja murekohad. Üle 900 vastuse analüüsimiseks rakendati nii kvalitatiivseid kui ka kvantitatiivseid meetodeid, sealhulgas TnT-LLM, BERT ja Word2Vec ning QCAmap, eesmärgiga luua süsteemsed kategooriad, mis peegeldavad õpetajate seisukohti ja tähelepanekuid. Töö keskendub kategoriseerimise protsessi uurimisele ja selle meetodite rakendatavusele haridusvaldkonnas. Tulemusena tõusid peamisteks muredeks usaldusvärsuse küsimused, iseseisva mõtlemise oskuse vähenemine ja loovuse kahanemine.

1 Sissejuhatus

Tehisintellekti (AI) tööriistade, nagu ChatGPT ja Gemini, integreerimine üldharidussüsteemi on pakkunud uusi võimalusi, kuid toonud kaasa ka väljakutseid õpetajatele. RANDi uuringust Diliberti et al. (2024) selgub, et AI tööriistad aitavad õpetajaid tundide ettevalmistamisel ning õpilastele õppetöö personaliseerimisel. Kuigi ligi 18% õpetajatest kasutab regulaarselt AI-d, esineb siiski puudujääke koolituses, juurdepääsus ja tööriistade arusaamises. Eriti vähemate võimalustega piirkondades, mis võib süvendada hariduslikku ebavõrdsust.

AACE uuringus Kaplan-Rakowski et al. (2023) tuuakse välja, et õpetajad tunnevad muret vähesa juhendamise ja andmekaitse üle AI kasutamisel. Eestis tehtud uuring Laak and Aru (2024) näitab, et 49% Eesti üldharidusõpetajatest on kohandanud oma õpetamismeetmeid, lubades õpilastel tehisintellekti ideede genereerimiseks kasutada eesmärgiga süvendada kriitilise mõtlemise arendamist. Samuti tuvastati, et 74% õpetajatest kasutab neid vahendeid administratiivseteks ülesanneteks, näiteks e-kirjade vastamiseks.

Eelnimetatud uuringud sisaldasid nii kvantitatiivseid kui ka kvalitatiivseid küsimusi. AACE Kaplan-Rakowski et al. (2023) analüüsis kvantitatiivseid sisendeid SAS/STAT tarkvara abil, kvalitatiivseid aga kodeerimisskeemide kaudu.

Kuna paljud õpetajad ei kasuta veel oma töös AI-d, on edasised uuringud vajalikud, et mõista uute vahendite mõju haridusele ja toetada õpetajate kohanemist uute tehnoloogiatega.

Kvalitatiivsete andmete analüüsimiseks on oluline uurida erinevaid meetodeid, mis võimaldab kvalitatiivseid andmeid kvantifitseerida ja seeläbi põhjalikumalt analüüsida. Huvi andmete kvantifitseerimise vastu ilmnas juba varajastes

teadustöodes, näiteks Yule'i töös 1910. aastal ja esimesed kvantifitseerimismeetodid hakkasid ilmuma juba 1940. aastatel. (Young, 1981)

Tänapäeval on võimalik läbi viia ulatuslikke küsitlusi kasutades erinevaid tööriistu suurte tekstikogumite analüüsimiseks. On oluline tuvastada, millised tööriistad toimivad kõige paremini eestikeelsete andmetega või leida lahendusi, et kasutada analüüsimistööriistu eestikeelsete andmete jaoks.

Uurimuse andmestik koosneb enam kui 900 vastusest, mis on kogutud Eesti üldharidusõpetajate seas läbi viidud küsitlusest 2024. aasta märtsis. Küsitluses esitati mitmeid küsimusi, millele vastati vabas vormis tekstiga, eesmärgiga avastada peamised teemad ja mustrid õpetajate kogemustes ja arvamustes seoses tekstirobotite kasutamise hariduses.

Käesoleva töö eesmärgiks on analüüsida 905 õpetaja vastuseid küsimusele "Kirjeldage peamisi väljakutseid, küsimusi, hirme jms seoses tekstirobotitega". Analüüsiks kasutame erinevaid meetodeid, kvalitatiivset kui ka kvantitatiivseid. Lisaks analüüsile võrdleme ka erinevate meetodite tulemusi.

2 Meetodid

2.1 Teksti klasterdamise meetodid

Teksti suuremahulise töötlemise ja kategoriseerimise jaoks kasutasime suuri keelemodeleid, nagu GPT-4, et teksti mõista ning vastuseid rühmitada. Rakendasime raamistikku TnT-LLM (ing k *Taxonomy and Text classification using Large Language Models*) (Wan et al., 2024), mille puhul luuakse taksonoomia suurte keelemudelite abil, tagastades ka täpsemad alamkategooriad. TnT-LLM eesmärk on teha kogu protsess nii automatiseerituks kui võimalik, aga seetõttu on vajalik ka laialdane suurte keelemudelite kasutamine. TnT-LLM peaks ise genereerima vajalikud taksonoomiad teksti pealt ja saadud kategooriaid peaks saama kasutada ka teiste raamistike kasutamisel. TnT-LLM suuremahuline kasutus eeldab, et saadud vastuste pealt on võimalik luua lihtsamad mudelid, mis alamkategooriate loomisel töö keelemudelite eest ära teeks.

Lisaks eelmainitule kasutasime ka BERT (ing k *Bidirectional Encoder Representations from Transformers*) ja Word2Vec (ing k *Word to Vector*) mudelid. Konteksti analüüsimiseks ja mustrite kuvamiseks kasutasime BERT-i. Word2Vec-i rakendasime semantiliste seose leidmiseks vastuste vahel. BERT-i versioonidest kasutasime EstBERT mudelit, mis on ennast tõestanud kui suurema täpsusega versioon võrreldes mitmekeelsete mudelitega. Varasemalt on seda katsetatud rubriikide määramisel mille puhul jäi see vaadeldud mudelistest parimaks. (Tanvir et al., 2021)

id	name	description
1	Deterioration of Student Skills	Decline in critical thinking, language skills and independent learning motivation
2	Accuracy and Reliability Concerns	Uncertainty about AI-generated content accuracy and factual correctness
3	Academic Integrity Challenges	Maintaining assessment authenticity and redesigning evaluation methods
4	Teaching and Technical Adaptation	Challenges in pedagogical integration and effective AI tool usage
5	Creativity and Innovation Loss	Concerns about diminishing original thinking and creative expression
6	Privacy and Ethics Issues	Concerns about student data protection and educational fairness

Tabel 1. TnT-LLM klastrid koos kirjeldustega

1	Erosion of Independent Thinking	Concerns about reduced student creativity and self-learning
2	Language and Literacy Degradation	Declining language skills and text creation abilities
3	Academic Integrity Challenges	Difficulties in detecting and preventing AI-assisted work
4	Critical Thinking and Verification	Risks to analytical skills and doubts about content accuracy
5	Learning Process Disruption	Potential shortcuts undermining genuine learning efforts
6	Skill Acquisition Impediment	Preventing students from developing essential communication skills
7	Ethical and Responsible AI Use	Navigating appropriate and constructive AI integration
8	Technological Dependency	Concerns about over-reliance on AI tools and reduced cognitive effort

Tabel 2. Tõlgitud TnT-LLM

2.2 TnT-LLM

TnT-LLM raamistik töötab suurte keelemudelitega konkreetsete kontekstidega. Töötlesime andmeid väikses mahus korraga, suurte keelemudelite kasutamise limiitide tõttu. Keelemudelitele anti töötlemiseks vaid vastuste id ja konkreetse küsimuse vastus. Suured keelemudelid said eesmärgiks luua kuni 10 klastrit, keskmiselt loodi 7 klastrit 100 rea kohta. Claude'i poolt antud vastused olid kõrge kvaliteediga ja on toodud välja ka tabelis 1. GPT-4 piirab oma kasutamist väga kiirelt, saadud tulemused on sarnased Claude'iga.

Tõlkisime õpetajate antud vastused ka inglise keelde kasutades TartuNLP rakendusliidest (API). (Tartu NLP, n.d.) Tõlgitud vastuseid rakendasime sarnaselt originaalsetele vastustele, et katsetada, kas suured keelemudelid saavad paremini hakkama ingliskeelse tekstiga. Rakendades eestikeelse teksti pealt saadud klastreid, oli saadud tulemus sarnane, kuid eeliseks oli väiksem arv vastuseid, mida ei kategoriseeritud. Eestikeelsele tekstile sai sajast reast neliteist vastuseks *Undefined*, aga tõlgitud versioonil koos originaalsete klastritega jäi kategoriseerimata vaid üks. Samas näidete põhjal saab öelda, et mõned sildid, näiteks puuduva vastuse puhul, on üleliigselt lisatud. Vastused, millel on mitu tahku, näiteks vastus, mis märgib samal ajal ära autoriõigused ja täpsuse, on liikunud eetika klastrist valeinformatsiooni klasterisse. Antud muutus võib muidugi esineda ka esialgse eestikeelse versiooni uuesti jooksutamisel ning on näide piirangust, mida toob esile iga vastuse jaoks ühe klasteri valimine.

Kui Claude lõi uued klastrid vastavalt tõlgitud tekstile, siis oli varasema kuue kategooria asemel lõplik kategooriate arv kaheksa. Uued kategooriad on näha tabelis 2, sõnastus jäi samaks vaid ühe kategooria puhul - *Academic Integrity Challenges*. Varasem kirjeldus rõhus hinde andmise metoodika muutumisele, tõlgitud versioon keskendub AI poolt loodud materjali tuvastamisele. Kvantitatiivset analüüsi viisid läbi kolm rühmeliiget.

Gemini poolt loodud klastrid on võrdväärsed kvaliteedi poolt Claude'ga, aga loodud gruppide määramine üksikutele

Lack of critical thinking	Students may lose the ability to think critically and creatively.
Plagiarism and academic integrity concerns	Students may use LLMs to cheat on assignments or plagiarize work.
Student dependency on LLMs for learning	Students may become too reliant on LLMs and lose the ability to learn independently.
Lack of source criticism	Students may not be able to evaluate the information from LLMs critically.
Accuracy of information	LLMs may sometimes provide inaccurate or misleading information.
LLM usage fears in specific subjects	Teachers may have concerns about LLMs in subjects like foreign languages or programming.

Tabel 3. Gemini klastrid

Reduced Cognitive Engagement	Students' critical thinking skills and effort are reduced.
Inaccurate Information	Students receive and believe inaccurate information.
Creativity Decline	Students' creativity and self-expression decline.
Dependence on Technology	Over-reliance on technology for tasks.
Ethical Concerns	Ethical issues related to data privacy and usage.
Environmental Impact	Environmental concerns related to AI usage.
Lack of Understanding	Lack of understanding of AI and its functions.
Teacher Challenges	Challenges faced by teachers in adapting to AI.
Plagiarism Concerns	Concerns about students using AI to plagiarize.
Language Barriers	Difficulties due to language proficiency issues.

Tabel 4. Copilot klastrid

ridadele suuresti põrus, ainult veerand ridadest said endale väärtused. Sarnane tulemus oli ka Copilotit kasutades kus sammuti ainult veerand ridadest määrati lõpuks klasterisse. Vastavalt TnT-LLM-is välja toodud kuluarvutustele on klasterite loomine siiski üks kallimaid osasid ja seega tasub neid keelemudeleid hoida selleks puhuks.


2.3 BERT ja Word2Vec

Treenisime Word2Vec mudeli vastuste peal, et näha, kas on võimalik saada selle vanema raamistikuga kasutatavaid klastreid. Saadud andmeid võrdlesime nii kvalitatiivsete kui ka TnT-LLM-st saadud tulemustega. Katsetasime erinevate klasterite arvuga, viimane võrdlus sai tehtud kuue, üheksa ja kümne klasteriga. Kuue ja üheksa klasteriga saadud tulemused ei ühti päris täpselt teiste meetoditega. Teatud juhtudel esineb mitme sarnase tagasisidega klastreid, aga mitmed küllaltki sarnased vastused grupeeritakse siiski eraldi.

Kasutasime tartuNLP/EstBert mudelit, et tekstid tokeniseerida ja luua nende põhjal vektorid. Seejärel moodustasime klasterid BERTopicu raamistikuga. Kuigi klasterite nimed olid kohati arusaamatud ning mõni klaster koosnes ka vaid sidesõnadest, siis sobivate klasterite ümbernimetamisel saime siiski tähenduslikud klasterdused, mis aitavad hinnata õpetajate hirme ja arvamusi.

Peale BERTopicu katsetasime BERTi klasterite kirjeldamist läbi suure keelemudeli. Vastused kirjeldasid vaadeldud juhtudel kas suurimat või teist kõige suuremat kvalitatiivset klasteri nimetus ehk pigem kirjeldasid loodud klasteri nimetused üht osa kogu grupist, aga mitte kõiki. Pigem nõrgema kvaliteediga BERT klasteritel võib olla see ka parim võimalik tulemus.

Meeleoluanalüüs EstBERT128_sentiment (n.d.) mudeliga andis meile senisest erinevad klasterid. Meeleoluanalüüsi eesmärk on luua täpsemaid alamgrupe. Tulemused olid positiivsed, enamuse vaadeldud vastustest kirjeldasid meeleolu täpselt. Lühemate lausete puhul oli täpsus väiksem ning neutraalsed vastused loeti pigem negatiivseteks. Lausetel, mis



Tabel 5. EstBert klastrid ja nende esinemine (muudetud nimedega)

kirjeldasid iseseisva mõtlemises kadumist ja olukorda pigem märksõnadena kui päris lausetena, jäi analüüsi tulemus mitmel juhul neutraalseks.

2.4 Kvalitatiivne uurimus

Kvalitatiivseks küsimustiku vastuste analüüsiks kasutame veebirakendust QCMap (ing k *Qualitative Content Analysis*). QCMap on andmeanalüüsi tarkvara, mida kasutatakse tekstide käsitsi kodeerimisel ja analüüsimisel. See lubab kasutajatel kodeerida andmeid, seeläbi tuvastada korduvaid teemasid ning esitada tulemusi statistilise raportina. QCMap on eriti kasulik sisuanalüüsi meetodite rakendamisel ja toetab teadustööd, kus on vaja struktureerida ja analüüsida keerulisi tekstandmeid. Lisaks toetab see ka meeskonnatöid, kus kõik projektiga seotud liikmed saavad teksti kodeerimisesse panustada.

Kuna analüüsitavate vastuste arv oli üle 900, otsustasime tööjaotuse kasuks. Selline lähenemine oli vajalik, et vältida vigu ja säilitada ühtlane töötempo kogu analüüsi vältel. Vastused jaotati analüüsijate vahel proportsionaalselt, tagades, et iga osaleja vastutus oleks jõukohane.


Esimeseks tagasilöögiks oli asjaolu, et QCMap ei taga dokumendi värskust, kui seda redigeerib kaks isikut samal ajal. Et näha teise loodud klastreid ja klasterdusi, vajas veebileht värskendust, mis võttis aega. Sellega kadus töö efektiivsus, kuna korraga oli mõtet ainult ühel meist antud vastuste kallal töötada.

Olgugi, et tegemist on grupitööga ning tööde jaotus on oluline, oli kvalitatiivse küsimustiku analüüsi suureks katsumuseks hoida oma kolleegiga kindlat joont arusaamal, milliseid vastuseid mingi klaster esindab. Kvalitatiivset analüüsi viisid läbi kaks rühmaliiget.

3 Tulemused

3.1 Kvalitatiivse analüüsi tulemused

Nagu näha Tabelis 8, ilmnis kvalitatiivse analüüsi käigus mitmeid olulisi teemasid, mida küsimustiku vastajad käsitlesid. Märkimisväärne osa vastajatest (235) leiab, et tekstirobotid pärssivad inimeste arengut, tuues välja muresid, mis puudutavad näiteks õpilaste iseseisvat mõtlemisvõimet ja loomingulisust. Samuti tõstatati sageli tekkinud probleeme info tõepärasuse osas (151 kordust), mis viitab murele tekstirobotite võimekuse kohta esitada faktitäpseid vastuseid.



Tabel 6. TnT-LLM klastrid ja esinemine

Teisalt paistab silma suur hulk vastuseid (172), mis viitavad sellele, et õpetajad ei näe tekstirobotites otsest ohtu. Lisaks on osa (17) avaldanud rahulolu tekstirobotite potentsiaaliga õpetajatöö lihtsustamisel, nähes neis tuleviku tööriista, mis võib vähendada administratiivset koormust. Üksikutes näidetes toodi ka välja mõned ideed, mida tulevikus tekstirobotite väärkasutamise vastu rakendada. Üle 100 õpetaja vastas, et nad ei kasuta tekstiroboteid õpetajatöös. Seda põhjendatakse tihti kas vanade harjumustega või õpetatava aine olemusega olles AI tööriistale veel liiga keeruline. Veel üheks korduvaks teemaks on tehnilised ja kasutusprobleemid (176), mis raskendavad nende tööriistade laiemat kasutuselevõttu.

Mõned vastajad (58) rõhutavad, et õpetajad peavad muutma oma õpetusmeetodeid, et tekstiroboteid paremini integreerida. Siiski toovad mitmed esile ajapuuduse ja koolituste vähesuse, mis takistab tõhusat rakendamist. Täiendavalt viidatakse eetilistele ja turvalisuse küsimustele (58 kordust), mis võivad puudutada andmekaitset või tekstirobotite väärkasutamise võimalusi.

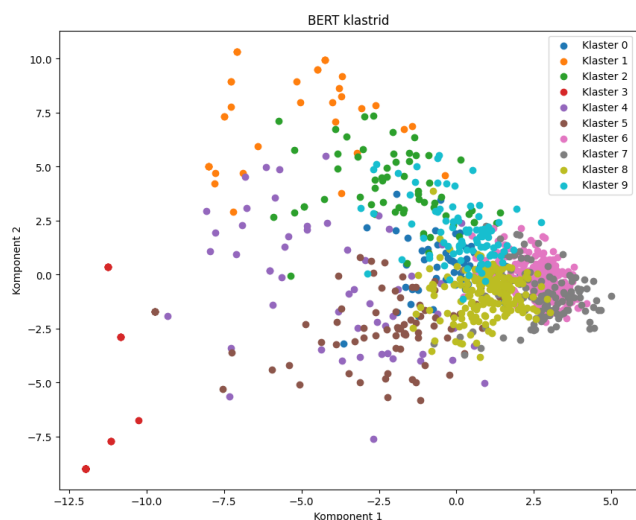
Samuti tõusetub küsimus tekstirobotite kasutamisest õpilaste seas. Väiksem hulk vastajatest (47) toob esile, et õpilaste puhul on raske nende kasutust tuvastada, ja mõned (45) rõhutavad, et õpilased ei oska tekstiroboteid piisavalt hästi rakendada.

Võrreldes teiste analüüsimeetoditega on tulemused üldiselt samad. Kategooriad, nagu "Pärsib inimeste arengut" ja "Info tõepärasus," mis domineerivad kordustelt, ilmnevad ka kvantitatiivses analüüsis (Tabel 6).

3.2 Kvantitatiivse analüüsi tulemused

Kvantitatiivse analüüsi käigus kasutades EstBert-i on Tabel 5 põhjal näha, et õpetajate suurimad hirmud seoses tekstirobotite kasutamisega on info usaldusväärsus, iseseisva analüüsimise ja mõtlemise oskus ning loovuse vähenemine. Samuti tunneb suur osa õpetajaid, et neil oleks vajalik tekstirobotite valdkonnas koolitusi läbida. Leidub ka vastajaid, kes ei tunne vajadust tekstiroboteid kasutada või ei ole nende kohta uurinud.

Copilot Tabel 4 ja Gemini Tabel 3 klasterdused toovad lisaks ka välja hirmud plagiadi, keskkonnamõjude ja eetilise osas.




Tabel 7. EstBert Põhikomponentide analüüs

3.3 Kvantitatiivse ja kvalitatiivse analüüsi võrdlus

Võrdlesime erinevaid loodud klastreid kvalitatiivse analüüsiga. Selleks kasutasime kümne klasteriga BERT versiooni. BERT klasterid ei kattunud antud juhul väga täpselt kvalitatiivse uurimusega, aga klasterdamise subjektiivsuse tõttu on vähemalt mingi erinevus oodatud. Keskmiselt oli iga kvalitatiivse uurimise klasteril kattuvus 7 erineva BERT klasteriga, suurim kattuvus oli keskmiselt 32%. Võttes arvesse seda, et mõne konkreetse teema puhul olid BERTi pakutud vastuste grupid detailsemad ning mitmeks jagatud, siis vaatasime ka kahte suurimat kattuvust. Suurim kattuvusega kvalitatiivses klasteris oli kahe BERT klasteri peale kokku 77% vastustest. Kaks üksikut BERT klasterit asusid 92% ja 65% ulatuses üksikutes kvalitatiivsetes klasterites. Vastused mainisid seda, et kas ei tunnetata ohtu seoses tekstirobotitega või on vähe kokkupuudet. Põhikomponentide analüüsist, tabel 7, on sarnaselt näha klasterite 1 ja 2 selge eristatavus ülejäänud tekstist. Selline tulemus teeb BERT analüüsi võrdlemisi tugevaks tööriistaks küsimustiku hindamise esimese etapina, sest võimaldab antud juhul anda väheste ressurssidega detailne grupp kümnele protsendile vastustest.

Word2Vec tulemused olid kehvemad kui BERTil, kui võrrelda kvalitatiivsete klasteritega. Kattuvusi oli vähem, keskmine suurim kattuvus klasterite peale kokku oli 27%. Suurim osakaal ühes kvalitatiivses klasteris oli 60%. Kahe suurima klasteri osakaal sellest samast kvalitatiivsest klasterist oli kokku 80%. Kuna antud kategooria on spetsiifiline ja seal oli vähe ridu, teema on õpetajatöö lihtsustamine, siis tundub tõenäoline, et kattuvus on pigem juhuslik.

Kasutasime TnT-LLM testimise raames GPT-4 mudelit ka ainult sildistamiseks. Võttes aluseks kvalitatiivsed kategooriad, sai 627. reast 412 endale sama tulemust kui kvalitatiivsel sildistamisel. 215. rea hulgas näis enamasti olevat tegemist vale kategoorimisega, ning erinevus ei seisnenud mitmeti mõistetatavates vastustes. Analüüsis kasutatud ridade arv tulenes GPT-4 poolt tulnud vastuses olnud ridade hulgast, keelemudelile laeti üles terve andmestik.



Tabel 8. QCMap klasterid ja nende esinemine

4 Diskussioon

Käesolev uurimus analüüsis Eesti üldhariduskoolide õpetajate vastuseid tekstirobotite kasutamise kohta, keskendudes nende hirmudele, arvamustele ja küsimustele. Kasutades nii kvalitatiivseid kui kvantitatiivseid meetodeid, selgus, et õpetajate mured on peamiselt seotud usaldusväärsuse, iseseisva mõtlemise ja loovuse vähenemisega. Kuigi suur osa õpetajatest veel AI-tööriistu ei kasuta, on ka neid, kes seda enda igapäevatoösse integreerivad.

Uuringu käigus analüüsisime küsimust "Kirjeldage peamisi väljakutseid, küsimusi, hirme jms seoses tekstirobotitega". Analüüsimate jäid küsimused "Mil viisil olete Te kohandanud oma tunde, õppematerjale ja kodutöid tekstirobotite tõttu?", "Kas ja kuidas lubate Te õppijatel tekstiroboteid õppetöös kasutada?", "Millistes ülesannetes ja olukordades lubate õppijatel tekstiroboteid õppetöös kasutada?", "Millisteks tööülesanneteks olete Te proovinud kasutada tekstiroboteid?" ja "Kas Te soovite teema kohta veel midagi öelda? (ei pea vastama)".

Kuigi suured keelemudelid pakkusid tõhusaid võimalusi andmete kategoriseerimiseks, oli nende kasutamine piiratud käsitletava andmehulga tõttu. Klasterdamine kasutades suuri keelemudeleid osutus väga kulukaks isegi võrdlemisi väikse andmehulga. TnT-LLM-i laiatrabelisemaks kasutamiseks peab tõenäoliselt rakendama mitut erinevat suure keelemudeli tüüpi ja teksti võimalikult palju eeltöötlema teiste tööriistadega. Samuti erines sama vastuse kategoriseerimine sõltuvalt etteantud tekstiandmete keelest.

Suurte keelemudelite kasutamise piirangute tõttu on oma roll mängida vähem ressurse nõudvatel lahendustel nagu BERT ja Word2vec. Antud uurimustöö näitas, et nende kahe omavahelises võrdluses on kasulikum kasutada BERT-i. Mõlemad tööriistad on vähenõudlikud, aga aitavad osa tekstist ise ära klasterdada. Tasub uurida kas on mõttekas ka nende meetodite rakendamine enne kvalitatiivse grupeerimisega alustamist, et hoida kokku aega ja töökulu. Vaadeldud tulemused üksi ei olnud piisavalt täpsed, et kasutada BERT-i või Word2vec teek klasterdamiseks ning alles hiljem rakendada suuri keelemudeleid.

Kokkuvõte

Käesolev uurimus tõi esile mitmeid olulisi aspekte, mis puudutavad tekstirobotite kasutamist Eesti üldhariduskoolides. Peamised murekohad on seotud usaldusväärsuse, iseseisva mõtlemise ja loovuse vähenemisega. Samuti ilmnes, et kuigi suur osa õpetajatest ei kasuta veel AI-tööriistu, on nende integreerimine igapäevatoösse siiski kasvav trend. Tulevikus on oluline jätkata uurimist, et mõista paremini tekstirobotite mõju haridusele ja toetada õpetajate kohanemist uute tehnoloogiatega.

References

- Diliberti, M., Schwartz, H. L., Doan, S., Shapiro, A. K., Rainey, L., & Lake, R. J. (2024). *Using artificial intelligence tools in k-12 classrooms*. RAND.
- EstBERT128_sentiment. (n.d.). *Tartu nlp, tartu ülikool* [Vaadatud 12.12.2024]. <https://translate.ut.ee/>
- Kaplan-Rakowski, R., Grotewold, K., Hartwick, P., & Papin, K. (2023). Generative ai and teachers' perspectives on its implementation in education. *Journal of Interactive Learning Research*, 34(2), 313–338.
- Laak, K.-J., & Aru, J. (2024). Generative ai in k-12: Opportunities for learning and utility for teachers. *International Conference on Artificial Intelligence in Education*, 502–509.
- Tanvir, H., Kittask, C., Eiche, S., & Sirts, K. (2021, May). EstBERT: A pretrained language-specific BERT for Estonian. In S. Dobnik & L. Øvrelid (Eds.), *Proceedings of the 23rd nordic conference on computational linguistics (nodalida)* (pp. 11–19). Linköping University Electronic Press, Sweden. <https://aclanthology.org/2021.nodalida-main.2/>
- Tartu NLP. (n.d.). *Tartu nlp tõlge, tartu ülikool* [Vaadatud 12.12.2024]. <https://translate.ut.ee/>
- Wan, M., Safavi, T., Jauhar, S. K., Kim, Y., Counts, S., Neville, J., Suri, S., Shah, C., White, R. W., Yang, L., Andersen, R., Buscher, G., Joshi, D., & Rangan, N. (2024). Tnt-llm: Text mining at scale with large language models. *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 5836–5847. <https://doi.org/10.1145/3637528.3671647>
- Young, F. W. (1981). Quantitative analysis of qualitative data. *Psychometrika*, 46(4), 357–388. <https://doi.org/10.1007/BF02293796>